(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 118051633 A
(43)申请公布日 2024.05.17

(21)申请号 202410148559.2

(22)申请日 2024.02.01

(71)申请人 合肥工业大学
地址 230009 安徽省合肥市包河区屯溪路193号
申请人 合肥综合性国家科学中心人工智能研究院(安徽省人工智能实验室)

(72)发明人 刘学亮 涂俊锋 闫坤祺 郝世杰 洪日昌 汪萌 蒋贻顺

(74)专利代理机构 合肥天明专利事务所(普通合伙) 34115
专利代理师 谢中用

(51)Int.Cl.
G06F 16/53(2019.01)
G06F 16/583(2019.01)
G06V 10/46(2022.01)
G06V 10/80(2022.01)
G06V 10/82(2022.01)
G06N 3/09(2023.01)

权利要求书2页 说明书7页 附图2页

(54)发明名称

一种基于长短映射的跨模态哈希检索方法

(57)摘要

本发明涉及跨模态检索技术领域,公开了一种基于长短映射的跨模态哈希检索方法,包括以下步骤:建立多模态数据集,多模态数据集中包括多个由图像以及对应的文本描述组成的图像文本描述对;构建长短映射方法;构建检索模型;哈希检索;本发明通过深度学习提取多维度特征,依据多维度特征之间的相关性差异实现不同维度特征之间的映射以增强低维特征的表现能力并提升检索准确率。

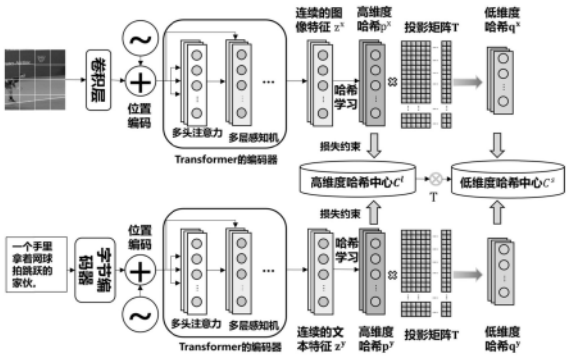

CN 118051633 A

1.一种基于长短映射的跨模态哈希检索方法,所采用的检索模型的构建和训练过程包括以下步骤:

步骤一,建立多模态数据集:多模态数据集包括N个由图像X_i以及对应的文本描述Y_i组成的图像文本描述对(X_i,Y_i),以及图像文本描述对(X_i,Y_i)对应的类别信息l_i,$1\leqslant i\leqslant N$;

步骤二,构建长短映射方法:对于一个图像文本描述对,将图像和文本描述分别输入到深度学习模型,得到图像高维哈希中心和文本高维哈希中心;通过投影模型分别将图像高维哈希中心和文本高维哈希中心映射为图像低维哈希中心和文本低维哈希中心;图像高维哈希中心和文本高维哈希中心统称为高维哈希中心C^l;图像低维哈希中心和文本低维哈希中心统称为低维哈希中心C^s;对投影模型进行训练,学习到一个能够将高维哈希中心映射到低维哈希中心的投影矩阵T;

步骤三,构建检索模型:检索模型包括图像模型、图像哈希学习模块、文本模型、文本哈希学习模块以及投影模块;

对于多模态数据集中的各图像文本描述对(X_i,Y_i),$1\leqslant i\leqslant N$,将图像X_i通过图像模型中的卷积层、位置编码和Transformer模型的编码器,生成连续的图像特征z^x,将文本描述Y_i通过文本模型的字节编码器、位置编码和Transformer模型的编码器,生成连续的文本特征z^y;将z^x和z^y分别输入到图像哈希学习模块和文本哈希学习模块,得到高维图像哈希表示p^x和高维文本哈希表示p^y;投影模块通过学习到的投影矩阵T将p^x和p^y分别映射为低维图像哈希表示q^x和低维文本哈希表示q^y;将p^x和p^y分别离散为高维图像离散哈希码h^x和高维文本离散哈希码h^y;将q^x和q^y分别离散为低维图像离散哈希码$\hat{h}^x$和低维文本离散哈希码$\hat{h}^y$;

基于h^x和h^y构建约束检索性能的相关性损失L_s以及约束离散化性能的量化损失L_q,得到总损失函数$L=L_s+\alpha L_q$;α表示用于平衡L_s和L_q的参数;通过多模态数据集和总损失函数L对检索模型进行训练;

哈希检索的过程包括:将查询数据输入到完成训练的检索模型,得到查询数据对应的低维离散哈希码,通过计算查询数据的低维离散哈希码与数据库中被查询数据的低维离散哈希码的相关性,取相关性最高的一个或者几个被查询数据作为查询结果;查询数据包括用于查询的图像或者文本描述,查询数据对应的低维离散哈希码为低维图像离散哈希码$\hat{h}^x$或者低维文本离散哈希码$\hat{h}^y$。

2.根据权利要求1所述的基于长短映射的跨模态哈希检索方法,其特征在于,所述图像哈希学习模块和文本哈希学习模块均采用多层感知机。

3.根据权利要求1所述的基于长短映射的跨模态哈希检索方法,其特征在于,步骤三中,将z^x输入到图像哈希学习模块得到高维图像哈希表示p^x时,具体包括:

将2l维度的连续图像特征z^x改变形状,得到l个图像二维向量$(z^x)'$,将每个图像二维向量$(z^x)'$输入到softmax函数获取哈希表示,得到l个图像二元码概率$(z^x)''$,将l个图像二元码概率$(z^x)''$拼接起来,得到维度为2l的高维图像哈希表示p^x;

将p^x离散为高维图像离散哈希码h^x时,具体包括:

将拼接高维图像哈希表示p^x所用到的l个图像二元码概率$(z^x)''$输入到argmax函数中,得到l个图像一元离散码$(z^x)'''$,最后将l个图像一元离散码$(z^x)'''$拼接起来,得到维度为l的高维图像离散哈希码h^x。

4.根据权利要求1所述的基于长短映射的跨模态哈希检索方法,其特征在于,步骤三中,将z^y输入到文本哈希学习模块得到高维文本哈希表示p^y时,具体包括:

将2l维度的连续文本特征z^y改变形状,得到l个文本二维向量$(z^y)'$,将每个文本二维向量$(z^y)'$输入到softmax函数获取哈希表示,得到l个文本二元码概率$(z^y)''$,将l个文本二元码概率$(z^y)''$拼接起来,得到维度为2l的高维文本哈希表示p^y;

将p^y离散为高维文本离散哈希码h^y时,具体包括:

将拼接高维文本哈希表示p^y所用到的l个文本二元码概率$(z^y)''$输入到argmax函数中,得到l个文本一元离散码$(z^y)'''$,最后将l个文本一元离散码$(z^y)'''$拼接起来,得到维度为l的高维文本离散哈希码h^y。

5.根据权利要求1所述的基于长短映射的跨模态哈希检索方法,其特征在于,所述相关性损失L_s为:

$$L_s = \sum_{i=1}^{N}\sum_{j=1}^{k}(c_{i,j}^{l}\, log\left(\mathbb{P}_{i,j}^{x}(h_j^x = 0)\right) + (1 - c_{i,j}^{l})\, log\left(\mathbb{P}_{i,j}^{x}(h_j^x = 1)\right)) +$$

$$\sum_{i=1}^{N}\sum_{j=1}^{k}(c_{i,j}^{l}\, log\left(\mathbb{P}_{i,j}^{y}(h_j^y = 0)\right) + (1 - c_{i,j}^{l})\, log\left(\mathbb{P}_{i,j}^{y}(h_j^y = 1)\right));$$

其中,k表示高维图像哈希表示p^x或者高维文本哈希表示p^y的码长,$c_{i,j}^{l} \in C^l$表示第i个训练样本的高维哈希中心C^l的第j比特值,$\mathbb{P}_{i,j}^{y}(h_j^y = 0)$表示第i个训练样本的高维文本哈希表示$p^y$的第j比特为0的概率,$\mathbb{P}_{i,j}^{x}(h_j^x = 0)$表示第i个训练样本的高维图像哈希表示$p^x$的第j比特为0的概率,$h_j^x$表示高维图像离散哈希码$h^x$的第j比特值,$h_j^y$表示高维文本离散哈希码$h^y$的第j比特值。

6.根据权利要求1所述的基于长短映射的跨模态哈希检索方法,其特征在于,所述量化损失L_q为:

$$L_q = 2 - \sum_{i=1}^{N}\sum_{j=1}^{k}(h_{i,j}^{x} - 1)^2 - \sum_{i=1}^{N}\sum_{j=1}^{k}(h_{i,j}^{y} - 1)^2;$$

其中,$h_{i,j}^{x}$表示第i个训练样本的高维图像离散哈希码h^x的第j比特值,$h_{i,j}^{y}$表示第i个训练样本的高维文本离散哈希码h^y的第j比特值。

7.根据权利要求1所述的基于长短映射的跨模态哈希检索方法,其特征在于,步骤二中,对投影模型进行训练时,具体包括:采用两组尺寸不同的哈达玛矩阵中的所有列向量或者所有行向量作为高维哈希中心C^l和低维哈希中心C^s,其中l,s分别表示高维哈希中心的码长和低维哈希中心的码长;然后设计一个单层的投影模型,并利用C^l、C^s作为投影模型的监督标签进行约束学习,通过学习到的投影矩阵T完成从高维哈希码到低维哈希码的映射:$T*C^s=C^l$;投影模型的目标函数M为:$M = \sum_{i=1}^{N}\left\|C_i^l - TC_i^s\right\|_F^2 + \lambda\left\|T\right\|_F^2$;其中,$C_i^l$表示第i个图像文本描述对相应的高维哈希中心监督标签;C_i^s表示第i个图像文本描述对相应的低维哈希中心监督标签;λ表示一个用于平衡多项损失大小的常量;$||\cdot||_F$表示F范数。

一种基于长短映射的跨模态哈希检索方法

技术领域

[0001] 本发明涉及跨模态检索技术领域,具体涉及一种基于长短映射的跨模态哈希检索方法。

背景技术

[0002] 随着互联网的普及应用,多模态数据以爆炸级的速度在互联网上增长,如何利用这些多媒体数据成为了一个热门的话题。例如,在进行文本搜索图像的任务中,传统方案对图像进行文本标注后,依据文本关键词检索出相关图片。这种做法不仅耗时耗力,而且效果并不良好、无法准确运用知识进行匹配。传统的跨模态检索算法首先将多模态数据投影到公共的子空间,然后依据数据间的临近度量来判断多模态数据是否相似,最后返回查询到的相似模态数据。

[0003] 这些方法依据特征提取方法的不同可以将算法分为:(1)子空间方法;(2)深度学习方法。子空间方法利用投影矩阵将高维数据投影到公共空间;深度学习方法利用深度学习优秀的特征抽取能力构建公共空间。

[0004] 另外,若依据度量空间划分,则这些方法可以划分为:(1)欧式空间度量方法;(2)汉明空间度量方法。欧式空间度量方法是将多模态数据投影到公共的欧式空间,最后用欧式空间的距离度量公式计算相关性;汉明空间度量方法目的是将数据投影到离散的汉明空间,最后利用简单的与或非二进制算法计算汉明距离,从而简化相关性的计算成本。

[0005] 汉明空间度量的方式相比欧式空间度量方式有两大好处:(1)存储成本低;(2)计算复杂度小。计算机最容易存储的数据为二进制数据,而汉明空间正好就是由二进制数组成,因此相比十进制的欧式空间来看,汉明空间度量方式的存储成本更为经济。其次,由于汉明空间的度量方式采用与或非运算,因此其计算成本比较欧式空间的四则运算更为高效。跨模态哈希检索因为这两个优势在近些年来得到了广泛的关注。

发明内容

[0006] 为解决上述技术问题,本发明提供一种基于长短映射的跨模态哈希检索方法,通过深度学习提取多维度特征,依据多维度特征之间的相关性差异实现不同维度特征之间的映射以增强低维特征的表现能力并提升检索准确率。

[0007] 为解决上述技术问题,本发明采用如下技术方案:

[0008] 一种基于长短映射的跨模态哈希检索方法,所采用的检索模型的构建和训练过程包括以下步骤:

[0009] 步骤一,建立多模态数据集:多模态数据集包括N个由图像X_i以及对应的文本描述Y_i组成的图像文本描述对(X_i,Y_i),以及图像文本描述对(X_i,Y_i)对应的类别信息l_i,$1\leqslant i\leqslant N$;

[0010] 步骤二,构建长短映射方法:对于一个图像文本描述对,将图像和文本描述分别输入到深度学习模型,得到图像高维哈希中心和文本高维哈希中心;通过投影模型分别将图

像高维哈希中心和文本高维哈希中心映射为图像低维哈希中心和文本低维哈希中心;图像高维哈希中心和文本高维哈希中心统称为高维哈希中心C^l;图像低维哈希中心和文本低维哈希中心统称为低维哈希中心C^s;对投影模型进行训练,学习到一个能够将高维哈希中心映射到低维哈希中心的投影矩阵T;

[0011] 步骤三,构建检索模型:检索模型包括图像模型、图像哈希学习模块、文本模型、文本哈希学习模块以及投影模块;

[0012] 对于多模态数据集中的各图像文本描述对(X_i,Y_i),$1\leqslant i\leqslant N$,将图像X_i通过图像模型中的卷积层、位置编码和Transformer模型的编码器,生成连续的图像特征z^x,将文本描述Y_i通过文本模型的字节编码器、位置编码和Transformer模型的编码器,生成连续的文本特征z^y;将z^x和z^y分别输入到图像哈希学习模块和文本哈希学习模块,得到高维图像哈希表示p^x和高维文本哈希表示p^y;投影模块通过学习到的投影矩阵T将p^x和p^y分别映射为低维图像哈希表示q^x和低维文本哈希表示q^y;将p^x和p^y分别离散为高维图像离散哈希码h^x和高维文本离散哈希码h^y;将q^x和q^y分别离散为低维图像离散哈希码$\hat{h}^x$和低维文本离散哈希码$\hat{h}^y$;

[0013] 基于h^x和h^y构建约束检索性能的相关性损失L_s以及约束离散化性能的量化损失L_q,得到总损失函数$L=L_s+\alpha L_q$;α表示用于平衡L_s和L_q参数;通过多模态数据集和总损失函数L对检索模型进行训练;

[0014] 哈希检索的过程包括:将查询数据输入到完成训练的检索模型,得到查询数据对应的低维离散哈希码,通过计算查询数据的低维离散哈希码与数据库中被查询数据的低维离散哈希码的相关性,取相关性最高的一个或者几个被查询数据作为查询结果;查询数据包括用于查询的图像或者文本描述,查询数据对应的低维离散哈希码为低维图像离散哈希码$\hat{h}^x$或者低维文本离散哈希码$\hat{h}^y$。

[0015] 进一步地,所述图像哈希学习模块和文本哈希学习模块均采用多层感知机。

[0016] 进一步地,步骤三中,将z^x输入到图像哈希学习模块得到高维图像哈希表示p^x时,具体包括:

[0017] 将21维度的连续图像特征z^x改变形状,得到l个图像二维向量$(z^x)'$,将每个图像二维向量$(z^x)'$输入到softmax函数获取哈希表示,得到l个图像二元码概率$(z^x)''$,将l个图像二元码概率$(z^x)''$拼接起来,得到维度为2l的高维图像哈希表示p^x;

[0018] 将p^x离散为高维图像离散哈希码h^x时,具体包括:

[0019] 将拼接高维图像哈希表示p^x所用到的l个图像二元码概率$(z^x)''$输入到argmax函数中,得到l个图像一元离散码$(z^x)'''$,最后将l个图像一元离散码$(z^x)'''$拼接起来,得到维度为l的高维图像离散哈希码h^x。

[0020] 进一步地,步骤三中,将z^y输入到文本哈希学习模块得到高维文本哈希表示p^y时,具体包括:

[0021] 将21维度的连续文本特征z^y改变形状,得到l个文本二维向量$(z^y)'$,将每个文本二维向量$(z^y)'$输入到softmax函数获取哈希表示,得到l个文本二元码概率$(z^y)''$,将l个文本二元码概率$(z^y)''$拼接起来,得到维度为2l的高维文本哈希表示p^y;

[0022] 将p^y离散为高维文本离散哈希码h^y时,具体包括:

[0023] 将拼接高维文本哈希表示p^y所用到的l个文本二元码概率$(z^y)''$输入到argmax函数中,得到l个文本一元离散码$(z^y)'''$,最后将l个文本一元离散码$(z^y)'''$拼接起来,得到维度

为l的高维文本离散哈希码h^y。

[0024] 进一步地,所述相关性损失L_s为:

[0025]
$$L_s = \sum_{i=1}^{N}\sum_{j=1}^{k}(c_{i,j}^{l}\, log\left(\mathbb{P}_{i,j}^{x}(h_j^x = 0)\right) + (1 - c_{i,j}^{l})\, log\left(\mathbb{P}_{i,j}^{x}(h_j^x = 1)\right)) + \sum_{i=1}^{N}\sum_{j=1}^{k}(c_{i,j}^{l}\, log\left(\mathbb{P}_{i,j}^{y}(h_j^y = 0)\right) + (1 - c_{i,j}^{l})\, log\left(\mathbb{P}_{i,j}^{y}(h_j^y = 1)\right));$$

[0026] 其中,k表示高维图像哈希表示p^x或者高维文本哈希表示p^y的码长,$c_{i,j}^{l} \in C^{l}$表示第i个训练样本的高维哈希中心C^l的第j比特值,$\mathbb{P}_{i,j}^{y}(h_j^y = 0)$表示第i个训练样本的高维文本哈希表示$p^y$的第j比特为0的概率,$\mathbb{P}_{i,j}^{x}(h_j^x = 0)$表示第i个训练样本的高维图像哈希表示$p^x$的第j比特为0的概率,$h_j^x$表示高维图像离散哈希码$h^x$的第j比特值,$h_j^y$表示高维文本离散哈希码$h^y$的第j比特值。

[0027] 进一步地,所述量化损失L_q为:

[0028]
$$L_q = 2 - \sum_{i=1}^{N}\sum_{j=1}^{k}\left(h_{i,j}^{x} - 1\right)^2 - \sum_{i=1}^{N}\sum_{j=1}^{k}\left(h_{i,j}^{y} - 1\right)^2;$$

[0029] 其中,$h_{i,j}^{x}$表示第i个训练样本的高维图像离散哈希码h^x的第j比特值,$h_{i,j}^{y}$表示第i个训练样本的高维文本离散哈希码h^y的第j比特值。

[0030] 进一步地,步骤二中,对投影模型进行训练时,具体包括:采用两组尺寸不同的哈达玛矩阵D_{2^n},D_2中的所有列向量或者所有行向量作为高维哈希中心C^l和低维哈希中心C^s:

[0031]
$$D_{2^n} = \begin{bmatrix} D_{2^{n-1}} & D_{2^{n-1}} \\ D_{2^{n-1}} & -D_{2^{n-1}} \end{bmatrix} = D_2 * D_{2^{n-1}};$$

[0032]
$$D_2 = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix};$$

[0033] 其中l,s分别表示高维哈希中心的码长和低维哈希中心的码长;然后设计一个单层的投影模型,并利用C^l、C^s作为投影模型的监督标签进行约束学习,通过学习到的投影矩阵T完成从高维哈希码到低维哈希码的映射:$T*C^s=C^l$;投影模型的目标函数M为:$M = \sum_{i=1}^{N}\left|\left|C_i^l - TC_i^s\right|\right|_F^2 + \lambda\left|\left|T\right|\right|_F^2$;其中,$C_i^l$表示第i个图像文本描述对相应的高维哈希中心监督标签;C_i^s表示第i个图像文本描述对相应的低维哈希中心监督标签;λ表示一个用于平衡多项损失大小的常量;$||\cdot||_D$表示F范数。

[0034] 与现有技术相比,本发明的有益技术效果是:

[0035] 首先,传统的哈希检索方案采用直接生成低维哈希码的方式进行检索,这样会导致模型在进行维度压缩时出现严重的信息丢失问题,为此,本发明提出一种长短映射的哈希检索方式,采用预定义的哈希标签作为监督信号学习一个长短哈希码间的无损投影矩阵T,实现维度压缩的同时保证哈希码的检索性能。其次,传统方案中的哈希方法存在优化难的问题,为此,本发明提出一种全新得哈希方法,将连续特征变换为多个二维向量,然后依据softmax函数将这些二维向量进行极值化,得到每个离散码的概率大小,最后依据argmax函数选取概率大的索引作为输出的离散码。这种方式可以有效地消除由于离散带来的深度学习模型不可导的问题,因此减少了模型在量化阶段出现的信息丢失。综合来看,本发明既

减少了在维度压缩时产生的信息丢失,同时也减少了模型训练时由离散化带来的信息丢失,因此检索性能更好。

附图说明

[0036] 图1为长短映射方案的示意图;

[0037] 图2为投影模型的原理示意图;

[0038] 图3为检索模型的示意图;

[0039] 图4为哈希学习和哈希离散的流程图;

[0040] 图5为实施检索时的流程图。

具体实施方式

[0041] 下面结合附图对本发明的一种优选实施方式作详细的说明。

[0042] 本发明提出了一种基于长短映射的跨模态哈希检索方法,在提取哈希特征的同时,关注到多维度的哈希特征,并采用一种长短映射的方法以实现高维空间到低维空间的转换和更加高效的检索性能。

[0043] 下面分步骤对本发明进行详细说明。

[0044] 1.多模态数据集的建立

[0045] 1.1,从现有公开的多模态数据集中收集由图像以及对应的文本描述组成的图像文本描述对。

[0046] 1.2,对互联网上的图像文本描述对进行爬虫收集。

[0047] 1.3,综合1.1,1.2中收集的数据合并为一个新的多模态数据集。

[0048] 2.长短映射方法的构建

[0049] 2.1,通常情况下,跨模态检索任务的性能跟模型最终提取特征的维度有一定的关联性,一般情况下提取特征的维度越高其检索性能越优。在哈希检索工作中,为了缩减存储成本,一般情况下提取的哈希特征维度一般都会很小(一般维度都小于64bit),而这直接导致哈希检索的性能下降。为了削弱因维度过低造成的检索性能影响,本发明设计一种基于长短映射的方案提升模型提取低维特征的能力。具体方案如图1所示,首先利用深度学习模型将图像提取一个高维特征,然后设计一个预训练的投影模型(长短映射算法),将高维特征映射到低维特征上,同时由预训练的投影模型保证其检索性能不变。对文本描述重复同样的操作。

[0050] 2.2,针对2.1中提到的预训练的投影模型,本发明采用哈希中心作为预训练标签,预先根据多模态数据集的类别信息选择一组高维哈希中心C^l和一组低维哈希中心C^s作为输出的哈希特征。然后根据高维哈希中心C^l和低维哈希中心C^s设计一个预训练的投影模型,该投影模型的主要负责将预定义好的长短标签进行投影,并学习一个投影矩阵T,实现$T*C^s=C^l$。

[0051] 选择哈达玛矩阵中的每列(行)向量作为哈希中心,因为哈达玛矩阵具有良好的性质,比如哈达玛矩阵的各行列向量正交、哈达玛矩阵的元素仅由两个值构成等。然后设计一个预训练的投影模型,学习投影矩阵T,投影模型如图2所示,优化的目标方程为:

[0052] $M=\sum_{i=1}^{N}\left\|C_i^l-TC_i^s\right\|_F^2+\lambda\left\|T\right\|_F^2$。

[0053] 3.检索模型的构建

[0054] 3.1,针对学到的投影矩阵,本发明设计了整体检索模型,首先采用目前流行的Transformer模型作为特征提取器提取多模态数据特征;其次根据特征提取网络的特征设计一个哈希学习模块,该哈希学习模块用于学习高维图像特征或者高维文本特征;最后将学习到的投影矩阵融入整体检索模型,与高维特征相乘后得到最终得低维特征。具体实现方法如图3所示。

[0055] 3.2,采用视觉Transformer模型提取图像特征,具体来说,视觉Transformer模型的工作流程是:首先采用一个卷积层将原图像(分辨率为224*224*3)按卷积核为32大小的方式生成7*7*512的特征图,然后将这个特征图展平为49*512的图像特征;为了提取图像的总体特征描述,需要在这49个图像特征中加入一个类别的编码向量作为最终图像的特征表示,此时的图像特征的维度为50*512;随后添加位置编码后经过Transformer编码器生成一个50*512维度的特征向量,取类别编码位置的特征向量作为连续的图像特征z^x。

[0056] 3.3,采用GPT-2模型提取文本特征,具体来说,GPT-2模型的工作流程是:首先将文本描述送入到一个字节编码器中,将文本编码为一组离散的数字表示,将每一句话按最长编码为32个编码后送入一个词编码模型中,对得到的编码词特征进行增强,得到32*512维度的特征向量;然后添加位置编码后送入一个Transformer模型的编码器,输出文本描述的所有编码特征(32*512);最后采用最大池化的方式取这32个词向量中最大的向量作为连续的文本特征z^y。

[0057] 3.4,采用多层感知机作为哈希学习模块,将连续的图像特征z^x、连续的文本特征z^y分别送入到各自的哈希学习模块,将原本512维的图像特征z^x或者文本特征z^y生成一种哈希表示。生成哈希表示的方法有三种,分别是(1)sign函数、(2)tanh函数近似、(3)softmax函数近似。其中,sign函数可以直接生成离散哈希编码,但是由于sign函数非凸,所以导致出现模型优化难的问题;tanh函数近似的方式在模型优化至离散时会出现梯度消失的问题,这导致模型训练时间越久越困难。基于以上原因,本发明提出第三种哈希生成方式:采用softmax函数获取哈希表示,因为softmax函数可以将生成的离散编码投影到概率空间,因此softmax函数生成哈希的方式不会出现梯度消失的问题。具体来说,本发明将得到的连续的图像特征或者文本特征,改变为256*2维度的特征向量,其中总共有256个二维特征向量,然后针对每一个二维特征向量进行二元softmax,得到256个bit的二元码概率,其中,选择每个二维特征的第一个值作为该比特位表示0的概率、第二个值作为该比特位表示1的概率:这样就得到了一个哈希码的连续概率表示,即得到高维图像哈希表示p^x和高维文本哈希表示p^y;最后采用argmax函数选择这个二维向量最大维度的索引作为表示哈希码的离散值,并将这一组离散的编码拼接起来即可获得最终的哈希码,即获得高维图像离散哈希码h^x和高维文本离散哈希码h^y:

[0058] 上述通过argmax函数获得h^x和h^y的过程,更加细致的说明如下:获取到$p^x\in\mathbb{R}^{2l}$和$p^y\in\mathbb{R}^{2l}$后,采用一种选择策略进行离散化,将原本的连续哈希表示转换为离散哈希码h^x,$h^y\in\{-1,+1\}^l$;其中$\mathbb{R}$表示连续的实数空间,l表示高维离散哈希码的码长,{-1,+1}表示离

散空间;选择策略可以表示为:

[0059] $$h_i = \begin{cases} 0 & 如果 p_i[0] > p_i[1] \\ 1 & 如果 p_i[0] \le p_i[1] \end{cases};$$

[0060] 其中h_i表示高维离散图像(或者文本)哈希码的第i比特位;$p_i \in \mathbb{R}^2$表示图像(或者文本)的哈希表示,但将原本的21维度拆分成了1个2维的向量。为简单表述,选择策略的公式可以采用python中numpy库函数内置的argmax函数代替。

[0061] 同理,将q^x和q^y分别离散为低维图像离散哈希码$\hat{h}^x$和低维文本离散哈希码$\hat{h}^y$,也是通过argmax函数实现的,与上述将p^x和p^y分别离散为高维图像离散哈希码h^x和高维文本离散哈希码h^y的过程相同。上述流程参考图4。

[0062] 3.5,获得到了256维度的哈希表示p^x、p^y后,此时得到的哈希表示维度较高,因此利用上述预训练的投影模型获取低维哈希。具体流程是将学到的投影矩阵T与高维图像哈希表示p^x、高维文本哈希表示p^y进行相乘操作,得到低维图像哈希表示q^x和低维文本哈希表示q^y。由于长短映射的方案是经过一个预训练投影模型生成的,所以长短映射的方案能够保证高维哈希到低维哈希的无损失转换,可以提升检索准确率。

[0063] 3.6,对整体检索模型定义损失函数,根据跨模态哈希检索的方法,定义两个损失函数:(1)相关性损失、(2)量化损失。相关性损失约束检索性能,量化损失约束离散化性能。

[0064] 相关性损失L_s计算如下:

[0065] $$L_s = \sum_{i=1}^{N}\sum_{j=1}^{k}(c_{i,j}^{l}\, log\left(\mathbb{P}_{i,j}^{x}(h_j^x = 0)\right) + (1 - c_{i,j}^{l})\, log\left(\mathbb{P}_{i,j}^{x}(h_j^x = 1)\right)) + \sum_{i=1}^{N}\sum_{j=1}^{k}(c_{i,j}^{l}\, log\left(\mathbb{P}_{i,j}^{y}(h_j^y = 0)\right) + (1 - c_{i,j}^{l})\, log\left(\mathbb{P}_{i,j}^{y}(h_j^y = 1)\right));$$

[0066] 其中其中,k表示高维图像哈希表示p^x或者高维文本哈希表示p^y的码长,$c_{i,j}^{l} \in C^l$表示第i个训练样本的高维哈希中心C^l的第j比特值,$\mathbb{P}_{i,j}^{y}(h_j^y = 0)$表示第i个训练样本的高维文本哈希表示$p^y$的第j比特为0的概率,$\mathbb{P}_{i,j}^{x}(h_j^x = 0)$表示第i个训练样本的高维图像哈希表示$p^x$的第j比特为0的概率,$h_j^x$表示高维图像离散哈希码$h^x$的第j比特值,$h_j^y$表示高维文本离散哈希码$h^y$的第j比特值。

[0067] 量化损失L_q计算如下:

[0068] $$L_q = 2 - \sum_{i=1}^{N}\sum_{j=1}^{k}(h_{i,j}^{x} - 1)^2 - \sum_{i=1}^{N}\sum_{j=1}^{k}(h_{i,j}^{y} - 1)^2;$$

[0069] 最终,结合相关性损失和量化损失得到总的损失函数$L = L_s + \alpha L_q$,本实施例中,取$\alpha = 0.01$。

[0070] 4.哈希检索流程:

[0071] 将上述检索模型应用于哈希检索任务中。哈希检索任务通常由一个查询样本(称为查询数据)在被查询的数据(被查询数据库)中查找到与之相关的数据;根据检索任务要求,首先需要将被查询数据库的所有数据转换为低维哈希码并存储,然后当有查询数据时,将查询数据输入上述检索模型,首先进行特征提取后,生成高维哈希码,然后依据预训练得到的投影模型生成低维哈希码,离散后得到低维离散哈希码,最后通过计算低维离散哈希

码与被查询数据库中数据的低维哈希码的相关性,得到距离矩阵,距离矩阵最后用于输出K个最小的索引,这K个索引就是最后的检索结果。其中,查询数据包括用于查询的图像或者文本描述。

[0072] 对于本领域技术人员而言,显然本发明不限于上述示范性实施例的细节,而且在不背离本发明的精神或基本特征的情况下,能够以其他的具体形式实现本发明。因此无论从哪一点来看,均应将实施例看作是示范性的,而且是非限制性的,本发明的范围由所附权利要求而不是上述说明限定,因此旨在将落在权利要求的等同要件的含义和范围内的所有变化囊括在本发明内,不应将权利要求中的任何附图标记视为限制所涉及的权利要求。

[0073] 此外,应当理解,虽然本说明书按照实施方式加以描述,但并非每个实施方式仅包含一个独立技术方案,说明书的这种叙述方式仅仅是为了清楚起见,本领域技术人员应当将说明书作为一个整体,各实施例中的技术方案也可以经适当组合,形成本领域技术人员可以理解的其他实施方式。

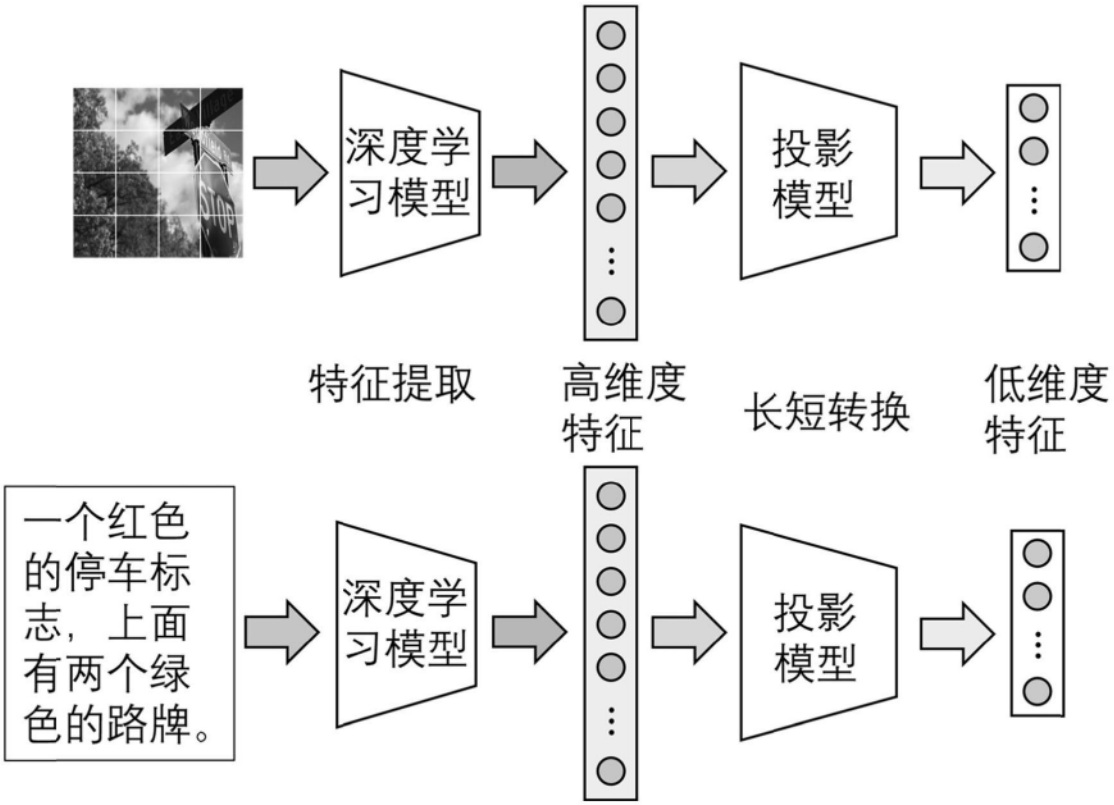
深度学习模型
投影模型
特征提取
高维度特征
长短转换
低维度特征
一个红色的停车标志，上面有两个绿色的路牌。
深度学习模型
投影模型

图1

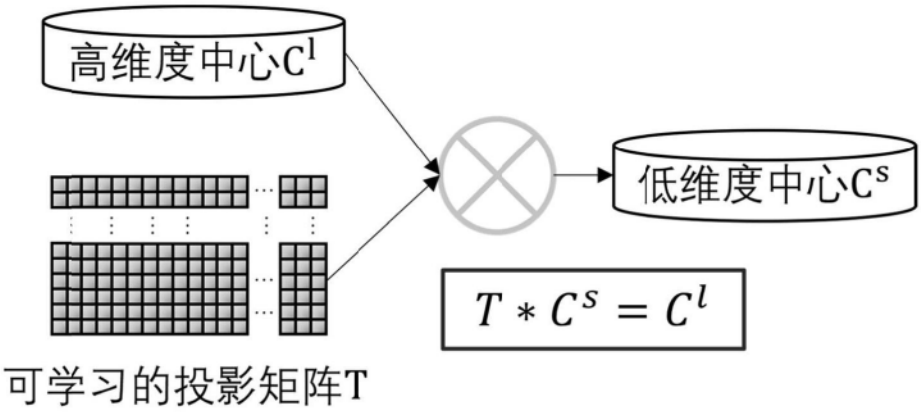
高维度中心C^l
低维度中心C^s
$T * C^s = C^l$
可学习的投影矩阵T

图2

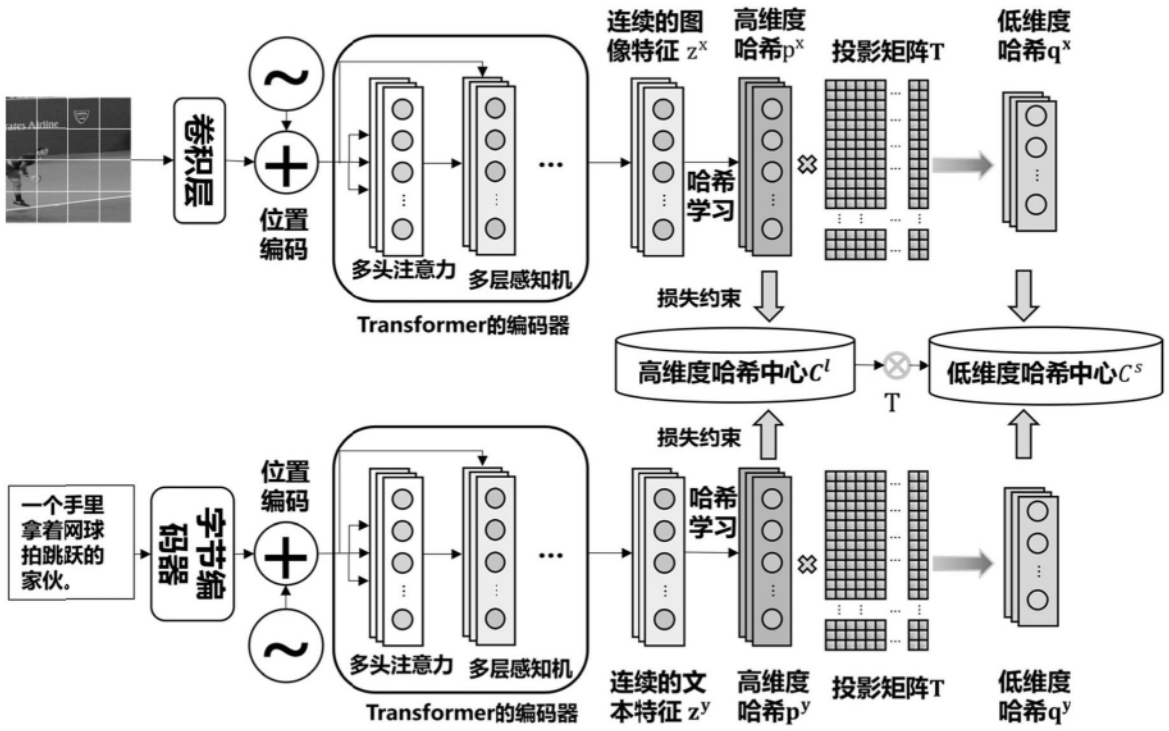
卷积层
位置编码
多头注意力
多层感知机
Transformer的编码器
连续的图像特征 z^x
高维度哈希p^x
投影矩阵T
低维度哈希q^x
哈希学习
损失约束
高维度哈希中心C^l
T
低维度哈希中心C^s
一个手里拿着网球拍跳跃的家伙。
字符编码器
位置编码
多头注意力
多层感知机
Transformer的编码器
连续的文本特征 z^y
高维度哈希p^y
投影矩阵T
低维度哈希q^y

图3

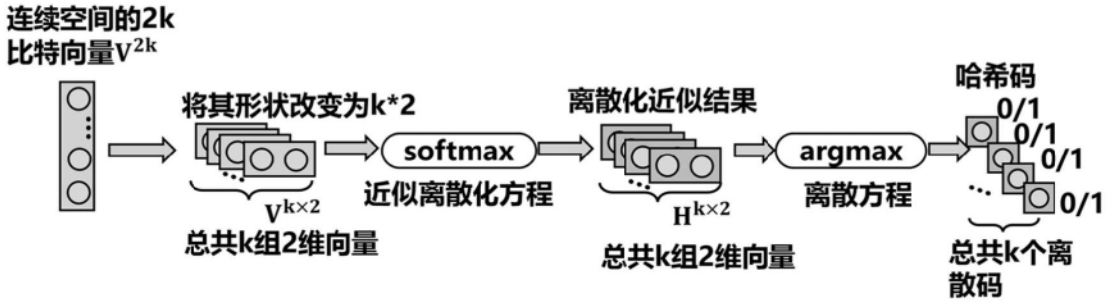
连续空间的2k比特向量V^{2k}
将其形状改变为k*2
$V^{k\times2}$
总共k组2维向量
softmax
近似离散化方程
离散化近似结果
$H^{k\times2}$
总共k组2维向量
argmax
离散方程
哈希码
0/1
0/1
0/1
0/1
总共k个离散码

图4

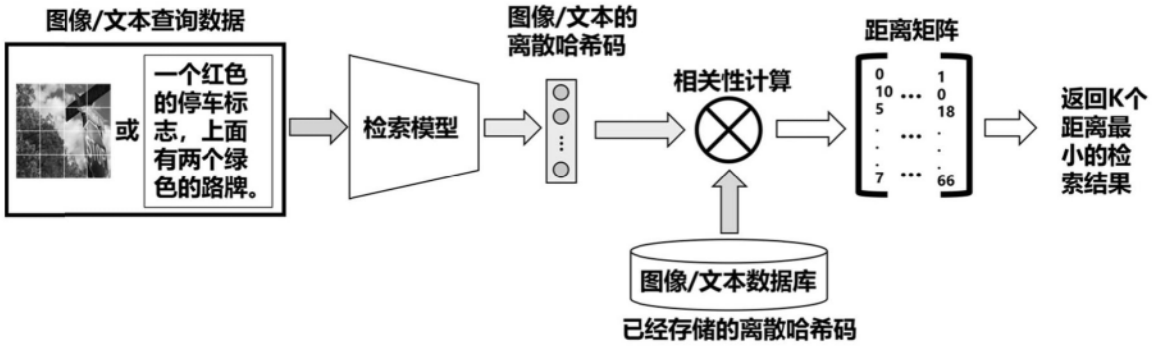
图像/文本查询数据
或
一个红色的停车标志，上面有两个绿色的路牌。
检索模型
图像/文本的离散哈希码
相关性计算
距离矩阵
图像/文本数据库
已经存储的离散哈希码
返回K个距离最小的检索结果

图5